ENTREGA 1

Machine Learning: Aprendizaje No Supervisado

Un recomendador que entiende el orden: perfumes

8 DE NOVIEMBRE DE 2026 · VERSIÓN CORREGIDA

PROF. DANILO GÓMEZ

Integrantes: Lucas Torres y María Jesús Salinas

1. Resumen Ejecutivo

El trabajo construye un recomendador secuencial de perfumes: a partir de los perfumes que una persona reseñó y del orden en que lo hizo, predice cuál buscará después. Se usó Amazon Reviews 2023 (McAuley Lab, UCSD; Hou et al., 2024), categorías *Beauty and Personal Care* y *All Beauty*, solo perfumes. Tras el 5-core quedan 39.032 interacciones, 5.398 usuarios y 2.125 perfumes; el profesor autorizó la excepción al mínimo de 50.000 interacciones para conservar una base solo de perfumes.

Con protocolo leave-last-out y ranking sobre el catálogo completo, SASRec (Transformer causal en PyTorch) supera a las tres líneas base en las nueve métricas: HitRate@10 = 17,4% y NDCG@10 = 0,098, un 31% sobre la mejor línea base (reglas de asociación con umbrales ajustados en validación) y 1,9 veces la popularidad. Su ventaja se concentra en los perfumes populares: en la cola larga rinde peor que ítem–ítem, evidencia del sesgo de popularidad. El modelo pesa 0,76 MB, entrena en 40 s y aprende sin supervisión la separación por género (79% de vecinos del mismo género, contra 50% al azar). **Todas las cifras, el modelo y *metricas.csv* provienen de una única corrida del notebook** (semilla 42, GPU), registrada en *data/resumen_corrida.json*.

2. Desarrollo Metodológico

2.1 Base, filtro de perfumes y 5-core

Cada reseña es una interacción (usuario, perfume, marca de tiempo) y cada perfume tiene marca, género, precio y valoración. Un producto entra si su categoría incluye *Fragrance* o si su título dice perfume, EDT, EDP, cologne u otros, excluyendo *fragrance-free* y *unscented*; un filtro más amplio superaba las 50.000 interacciones, pero el 27% de sus ítems eran cremas y protectores solares. Se eliminaron nulos y duplicados (se conserva la primera reseña) y se aplicó un 5-core iterativo que converge en 14 rondas. El género se asigna revisando primero *Unisex* y usando el título si la ruta de categorías no informa: 1.085 de mujer, 948 de hombre, 12 unisex y 80 sin dato.

Ronda	Interacciones	Usuarios	Perfumes	Marcas nicho presentes
Inicio	1.171.421	920.100	63.650	Xerjoff 15, Kilian 87, MFK 63, Creed 12
1	80.103	11.489	13.321	Xerjoff 3, Kilian 11, MFK 18
2	59.042	10.064	3.347	MFK 2, Nishane 2
14 (final)	39.032	5.398	2.125	MFK 1, Nishane 2

Tabla 1. Evolución del filtro 5-core (mínimos exigidos: 50.000 / 2.000 / 500).

Quienes compran perfumes de nicho rara vez reseñan cinco perfumes en Amazon, por lo que la base final es de perfumes masivos y de diseñador (mediana de US$ 29). Las secuencias se ordenan por fecha y los perfumes se indexan desde 1 (índice 0 = relleno).

2.2 Exploración y evidencia de orden

La densidad es 0,34% y la mediana de largo es 6 perfumes (95% con 14 o menos). El 20% de perfumes más reseñados concentra el 59% de las interacciones. **El orden importa:** dos perfumes consecutivos comparten marca el 10,2% de las veces y dos tomados al azar del mismo historial el 7,5% (1,35 veces más); con el género la razón es 1,03, porque cada persona compra casi siempre del mismo género.

2.3 Protocolo, métricas y líneas base

Leave-last-out: el último perfume es prueba, el penúltimo validación y el resto entrenamiento. Cada modelo ordena los 2.125 perfumes (sin los ya vistos) y se calculan HitRate, NDCG = $1/\log_2(r+1)$ y MRR = $1/r$ para K = 5, 10 y 20, verificadas a mano en un usuario (r = 5: NDCG@5 = 0,3869, MRR@5 = 0,2). Líneas base: **popularidad**; **reglas de asociación** (FP-Growth sobre las canastas de entrenamiento, reglas 1⇒1 con lift > 1, ordenadas por lift), con **soporte y confianza elegidos en validación** en una grilla de 5 × 5: gana soporte ≥ 3 canastas y confianza ≥ 0,20 (1.792 reglas, NDCG@10 val. = 0,065, contra 0,046 con los umbrales fijados a mano en la primera versión); e **ítem–ítem coseno** sobre los últimos 10 perfumes con decaimiento 0,8, también elegidos con validación.

2.4 SASRec

Embeddings de perfume y de posición, atención $\text{softmax}(QK^T/\sqrt{d})V$ con máscara triangular, bloques con residual, normalización y FFN, y puntaje $h_t \cdot E[i]$. Se entrena al estilo GPT (entrada 1…n−1, objetivo 2…n) con entropía cruzada sobre todo el catálogo: con 2.125 perfumes el softmax completo es barato y coincide con la evaluación. Adam, parada temprana con paciencia 10 sobre NDCG@10 de validación y semilla 42. **Decisión**

declarada: el largo máximo es 14 (percentil 95); al 3,7% de los usuarios se le descarta el inicio del historial y se conservan sus perfumes más recientes, que son los que más informan el siguiente.

Configuración	d	Bloques	Cabezas	Dropout	Parámetros	Mejor época	Tiempo	NDCG@10 val.
A	32	1	1	0,2	75.008	27	44 s	0,0919
B	64	2	2	0,2	187.520	11	29 s	0,0922
C (elegida)	64	2	2	0,5	187.520	18	40 s	**0,0937**

Tabla 2. Configuraciones de SASRec evaluadas en validación.

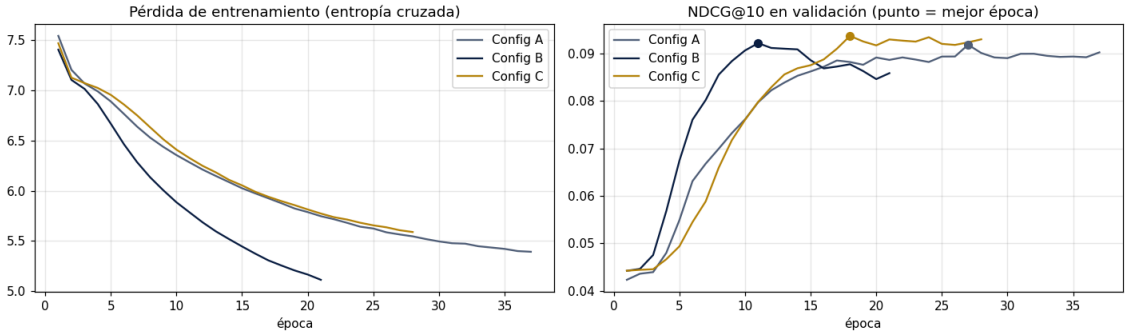


Figura 1. Pérdida de entrenamiento (izq.) y NDCG@10 de validación por época (der.).

B baja más la pérdida pero empeora en validación desde la época 11 (sobreajuste); C, con más dropout, generaliza mejor. Las tres quedan dentro de un 2%: pesa más usar la secuencia que el tamaño exacto del modelo.

3. Resultados

3.1 Comparación en prueba

Modelo	HR@5	NDCG@5	HR@10	NDCG@10	MRR@10	HR@20	NDCG@20	Cobertura@10
Popularidad	0,059	0,040	0,094	0,051	0,038	0,132	0,061	0,8%
Reglas (lift)	0,094	0,063	0,133	0,075	0,058	0,165	0,083	21,6%
Ítem–ítem coseno	0,076	0,051	0,114	0,063	0,047	0,168	0,076	99,3%
SASRec	**0,116**	**0,080**	**0,174**	**0,098**	**0,076**	**0,242**	**0,116**	**40,8%**

Tabla 3. Métricas en prueba, reportadas una sola vez (ranking sobre los 2.125 perfumes).

SASRec gana en las nueve métricas: NDCG@10 31% sobre las reglas y 57% sobre ítem–ítem. Ajustar los umbrales en validación convirtió a las reglas en la mejor línea base. Popularidad repite siempre los mismos 16 perfumes; las reglas cubren el 22% del catálogo, SASRec el 41% e ítem–ítem el 99%, con menor precisión. Los valores absolutos son bajos porque se ordena el catálogo completo; el paper original evalúa contra 100 negativos al azar.

3.2 Costo y segmentos

Modelo	Parámetros	Entrena	ms/usuario
Popularidad	2.125	—	0,57
Reglas	1.792 reglas	127 s	0,02
Ítem–ítem	4,5 M	0,5 s	0,08
SASRec	187.520	40 s (GPU)	0,11

Tabla 4. Costo de entrenamiento e inferencia (misma corrida).

Segmento (NDCG@10)	n	Reglas	Ítem–ítem	SASRec
Historial corto (≤ 5)	3.304	0,077	0,063	0,099
Historial largo (> 5)	2.094	0,072	0,063	0,097
Oculto popular (top 20%)	3.064	0,121	0,086	0,160
Oculto de cola larga	2.334	0,015	0,032	0,018

Tabla 5. NDCG@10 por segmento en prueba.

SASRec es más liviano que la matriz ítem–ítem y más rápido de entrenar que el minado de reglas. Rinde igual con historiales cortos y largos y domina cuando el perfume siguiente es popular (0,160 contra 0,121), pero en la cola larga (43% de los usuarios) lo supera ítem–ítem (0,032 contra 0,018): aprende los caminos frecuentes y empuja hacia perfumes conocidos.

4. Análisis de Usuarios y Embeddings

Tres usuarios. Los pesos de atención que se muestran son los del **último bloque**, en la última posición, y **promediados entre las cabezas**: indican en qué perfumes se fijó más el modelo, no una explicación causal completa. Para el usuario 3533 (Armaf, Nautica, Al Haramain, Reyane) SASRec propone perfumes masculinos del mismo estilo (Club de Nuit, Insurrection Wild, Nautica Voyage), con la atención repartida y su mayor peso en Nautica Voyage (0,26). Al usuario 4177 (Myrurgia Yacht Man, Maja, Jovan Musk) le sugiere dos variantes de Yacht Man: reconoce la línea de la marca. Falla con el usuario 481, que pasa de perfumes de lujo a atomizadores para hacer decants, un patrón raro en la base.

Embeddings. Proyectados con PCA, los perfumes de mujer y de hombre quedan separados aunque el modelo nunca vio el género: el vecino más cercano de cada perfume es del mismo género el 78,9% de las veces, contra 49,6% esperado al azar.

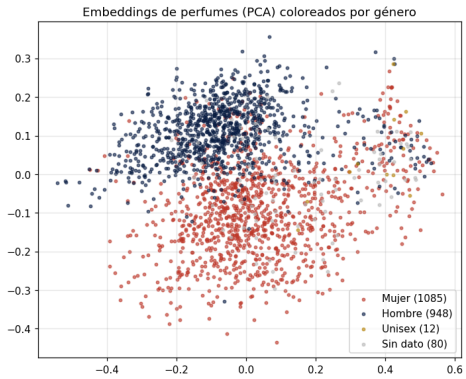


Figura 2. Embeddings de SASRec (PCA) coloreados por género.

5. Conclusiones y Plan para la Entrega 2

¿Vale la pena el Transformer? Sí, como motor principal: mejora en 31% el NDCG@10 de la mejor línea base a un costo mínimo y es el único modelo que aprovecha el orden de forma aprendida, justo donde la exploración mostró señal. Como en la cola larga lo supera ítem–ítem, conviene complementarlo con un método que no dependa de la popularidad. **Limitaciones:** una reseña no es una compra; la base carece de perfumes de nicho; quedan unos 20 accesorios (0,3% de las interacciones); el 3,8% de los perfumes no tiene género y el 24% no tiene precio.

Entrega 2. Dashboard en Streamlit publicado desde GitHub que carga *sasrec.pt* en CPU, con historial, atención, top 10 de SASRec puro y líneas base. Un analista LLM explicará las recomendaciones con contexto estructurado, sin agregar, quitar ni reordenar ítems, con prompt versionado, cinco pruebas de honestidad y registro de tokens, costo y latencia. Como innovación, un asesor en el que SASRec propone candidatos y el código los filtra por notas, acordes, ocasión y presupuesto, sin reemplazar la pestaña de SASRec puro.