APRENDIZAJE NO SUPERVISADO · ENTREGA 1

Un recomendador que entiende el orden: perfumes

Grupo 2 — Lucas Torres Baeza · María Jesús Salinas · Docente: Danilo Gómez Correa · Noviembre 2026

1. Rubro, base y hallazgos

Decisión que apoya: en una tienda de perfumes en línea, sugerir *el próximo perfume* de una persona según los que ya tiene y el orden en que los compró. **Base:** Amazon Reviews 2023 (McAuley Lab, UCSD; Hou et al., 2024), categorías *Beauty and Personal Care* y *All Beauty*, solo perfumes. Cada reseña es una interacción (usuario, perfume, marca de tiempo) y cada perfume trae marca, género, precio y valoración.

1. **Base muy dispersa.** Tras el 5-core quedan 39.032 interacciones, 5.398 usuarios y 2.125 perfumes, con una densidad de **0,34 %**.
2. **Historiales cortos.** La mediana es de 6 perfumes por persona; el 95 % tiene 14 o menos.
3. **Cola larga.** El 20 % de perfumes más reseñados reúne el 59 % de las interacciones. Los más populares son clásicos masculinos de precio medio (Nautica Voyage, Versace Man Eau Fraîche, Armaf Club de Nuit).
4. **El orden tiene información.** Dos perfumes *consecutivos* comparten marca el 10,2 % de las veces; dos perfumes al azar del mismo historial, el 7,6 % (**1,35×**). En cambio, el género casi no cambia con el orden (1,03×), porque cada persona compra casi siempre del mismo género.
5. **El Transformer aprende el rubro sin que se lo digan.** En sus embeddings, el vecino más cercano de cada perfume es del mismo género el 77 % de las veces, contra 50 % esperado al azar.

2. Decisiones

- **Qué cuenta como perfume.** Un producto entra si su categoría incluye *Fragrance* o si su título dice perfume/EDT/EDP/cologne..., excluyendo *fragrance-free* y *unscented*. Un primer filtro más amplio superaba las 50.000 interacciones, pero el 27 % de sus ítems eran cremas y protectores solares. Preferimos una base de perfumes reales con ≈ 39.000 interacciones. Cumple con holgura los mínimos de usuarios y de ítems, y el **profesor autorizó la excepción** al mínimo de interacciones.
- **Limpieza.** Si una persona reseñó el mismo perfume más de una vez, se conserva la primera reseña. Luego se aplica un 5-core iterativo (14 rondas). Las secuencias se ordenan por fecha y el índice 0 es el relleno.
- **Protocolo.** Leave-last-out: el último perfume es la prueba, el penúltimo la validación y el resto el entrenamiento. Cada modelo ordena **todo el catálogo**, sin los perfumes que la persona ya tiene. Se miden HitRate, NDCG y MRR @5/10/20, verificadas a mano en un usuario.
- **Líneas base.** Popularidad; reglas de asociación (FP-Growth sobre las canastas de entrenamiento, 6.077 reglas con lift > 1, ordenadas por lift); e ítem–ítem coseno. Para ítem–ítem, la validación eligió los últimos 10 perfumes con decaimiento 0,8.
- **SASRec.** Embeddings de perfume y de posición, atención causal con máscara triangular, bloques con residual, normalización y FFN, y puntaje h·E[i]. Se entrena al estilo GPT (entrada 1…n−1, objetivo 2…n) con **entropía cruzada sobre todo el catálogo**. Con 2.125 perfumes el softmax completo es barato y compara contra todos, igual que la evaluación. Se probaron tres configuraciones con parada temprana (paciencia 10, criterio NDCG@10 de validación). Las tres quedaron muy parejas (0,092–0,094). Se eligió la **C** (d = 64, 2 bloques, 2 cabezas, dropout 0,5). B, igual a C pero con dropout 0,2, se sobreajustó desde la época 11.

3. Resultados en prueba (reportados una sola vez)

Modelo	HR@5	NDCG@5	HR@10	NDCG@10	MRR@10	HR@20	NDCG@20	Cobertura@10
Popularidad	0,059	0,040	0,094	0,051	0,038	0,132	0,061	0,8 %
Reglas (lift)	0,050	0,032	0,094	0,046	0,032	0,162	0,063	37,9 %
Ítem–ítem coseno	0,076	0,051	0,114	0,063	0,047	0,168	0,076	99,3 %
SASRec (config C)	**0,116**	**0,080**	**0,174**	**0,098**	**0,076**	**0,242**	**0,116**	**40,8 %**

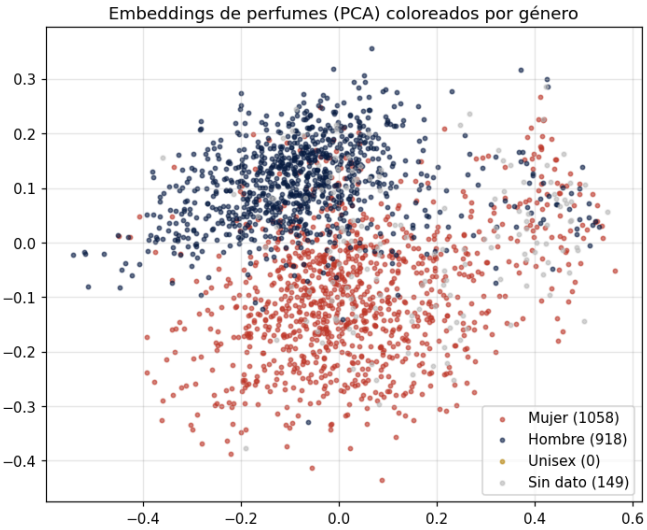
Cobertura@10: fracción del catálogo que aparece en algún top 10. Los valores absolutos son bajos porque cada modelo ordena los 2.125 perfumes; el paper original evalúa contra 100 negativos al azar, una prueba mucho más fácil.

SASRec gana en las nueve métricas. Su NDCG@10 es **+57 %** sobre ítem–ítem, la mejor línea base, y casi el doble que popularidad. Las reglas no superan a la popularidad en el top 10, aunque sí en el top 20: con historiales de 6 perfumes muy pocos pares alcanzan soporte, y el lift premia pares raros.

4. Costo y segmentos

Modelo	Parámetros	Entrena	ms/usuario
Popularidad	2.125	—	0,64
Reglas	6.077 reglas	131 s	0,04
Ítem–ítem	4,5 M (matriz)	0,6 s	0,10
SASRec	**187.520**	**38 s (GPU)**	**0,11**

NDCG@10 por segmento	Usuarios	Ítem–ítem	SASRec
Historial corto (≤ 5)	3.304	0,063	**0,099**
Historial largo (> 5)	2.094	0,063	**0,097**
Oculto popular (top 20 %)	3.064	0,086	**0,160**
Oculto de cola larga	2.334	**0,032**	0,018



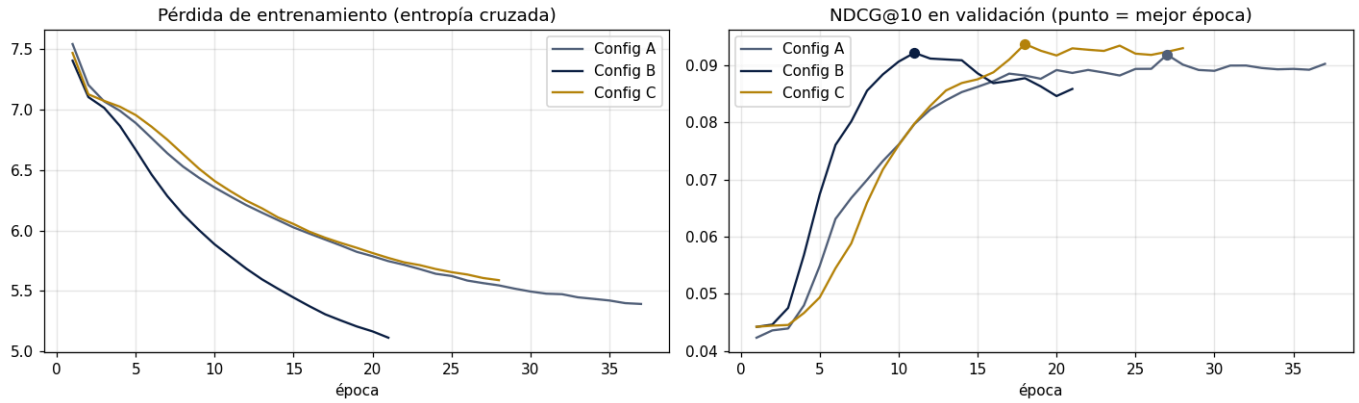
Embeddings de SASRec proyectados con PCA. Los perfumes de mujer (rojo) y de hombre (azul) quedan separados aunque el modelo nunca vio el género.

Lectura de costo y beneficio. SASRec pesa 0,76 MB, entrena en menos de un minuto y responde en 0,1 ms. Es más liviano que la matriz ítem–ítem y más rápido de entrenar que las reglas. Rinde igual con historiales cortos y largos. La ventaja se concentra en los perfumes populares: en la **cola larga** (43 % de los usuarios) rinde peor que ítem–ítem. Es el sesgo de popularidad que advierte el apunte.

Tres usuarios. Al usuario con Armaf, Nautica, Al Haramain y Reyane, SASRec le propone perfumes masculinos del mismo estilo; su atención se reparte entre varios perfumes y no solo en el último. Al que compró Yacht Man, Maja y Jovan Musk le sugiere **dos variantes de Yacht Man**, es decir, reconoce la línea de la marca. Falla con quien pasa de perfumes de lujo a atomizadores para hacer *decants*, un patrón raro en la base.

5. Conclusión: ¿vale la pena el Transformer?

> **Sí, como motor principal, con una salvedad.** SASRec mejora en 57 % el NDCG@10 a un costo mínimo y es el único modelo que aprovecha el orden de forma aprendida, que es justamente donde la exploración mostró que hay señal. Sin embargo, en la cola larga lo supera el ítem–ítem. Una tienda de perfumes también quiere vender nichos, así que conviene combinarlo con un método que no dependa de la popularidad.



Curvas por época de las tres configuraciones: pérdida de entrenamiento (izq.) y NDCG@10 en validación (der.; el punto marca la mejor época). B baja más la pérdida, pero empeora en validación después de la época 11.

Limitaciones. Una reseña no es una compra: hay personas que compran sin reseñar. Además, el filtro dejó unos 20 accesorios (atomizadores), que representan el 0,3 % de las interacciones. El 7 % de los perfumes no tiene género y el 24 % no tiene precio.

6. Plan para la Entrega 2

- **Dashboard en Streamlit** publicado desde GitHub, que carga `sasrec.pt` en CPU. Permite elegir un usuario de la base o armar un historial a mano, y muestra el top 10 de SASRec junto a las líneas base, con los pesos de atención de cada perfume del historial.
- **Analista IA (LLM de Gemini, plan gratuito, vía API).** Recibe un contexto estructurado: historial, recomendaciones, puntajes, atención, atributos y métricas del segmento. Escribe un análisis automático y responde un chat de seguimiento. Cuando hace falta vuelve a consultar al modelo, por ejemplo "¿y si agrego este perfume?". **Nunca agrega, quita ni reordena ítems.** Su prompt de sistema está versionado en `src/analista_prompt.md`. Se harán 5 pruebas de honestidad y se medirán tokens, costo y latencia. La llave queda en `st.secrets`, fuera de GitHub.
- **Innovación del grupo: perfil olfativo.** Cruzamos los perfumes con una base de fichas de Parfumo (notas de salida, corazón y base, acordes y ocasión). El cruce por marca y nombre ya encuentra la ficha del 45 % de los perfumes (58 % de los 100 más populares), que concentran casi la mitad de las reseñas. Con esto el dashboard muestra el perfil olfativo de cada usuario, el analista puede explicar con notas reales (por ejemplo, "comparte vainilla y ámbar con tus últimos perfumes"), y se agrega un modo para quien no tiene historial, que parte de las notas que le gustan. Esto ataca la debilidad de SASRec en la cola larga.

Repositorio: `data/secuencias.parquet`, `data/mapa_items.csv`, `data/metricas.csv`, `modelos/sasrec.pt` y el notebook ejecutado con semilla fija (42). Cita de la base: Hou, Y., Li, J., He, Z., Yan, A., Chen, X. y McAuley, J. (2024). *Bridging Language and Items for Retrieval and Recommendation*. arXiv:2403.03952.